

Informe del Caso de Estudio:

Employee Attrition y Monthly Income

Integrantes:

- Juan Jose Cordeiro
- Jose Antonio Favian Yujra Yana
- Leonardo Delgado Medrano
- Alan Franz Flores Campos
- Christian Coronel Condori

1. Planteamiento del problema y criterios de negocio

Contexto

El conjunto de datos contiene información de 1,470 empleados de una empresa (WA_Fn-UseC_HR-Employee-Attrition.csv). Se analizan dos problemas de negocio:

- Predicción del ingreso mensual (MonthlyIncome): problema de regresión. Objetivo técnico: estimar cuánto debería ganar un empleado en función de su perfil.
- Predicción de Rotación (Attrition): problema de clasificación binaria (Yes/No). Objetivo: detectar a los empleados con riesgo de renuncia.

Criterios de negocio y costos de error

- Regresión: un error absoluto grande en la predicción de sueldo puede implicar asignaciones presupuestarias ineficientes y descontento interno.
- Clasificación: se define la clase positiva como "el empleado renuncia". Los Falsos Negativos (FN) son especialmente costosos, ya que implican perder talento sin oportunidad de retención. Los Falsos Positivos (FP) generan costos de retención innecesarios.

Se asume que las características utilizadas están disponibles antes de la decisión de renuncia o el establecimiento del salario. El costo de un FN es mayor que el de un FP en el modelo de Attrition.

2. Exploración y calidad de datos

El dataset original cuenta con 1,470 registros y 35 columnas. A continuación se resumen los hallazgos de la fase exploratoria:

- No se detectaron valores nulos (df.isnull().sum() retorna ceros en todas las columnas).
- Se revisó la distribución de variables numéricas (histogramas, boxplots) y categóricas (countplots estratificados por Attrition).
- Se examinó la matriz de correlación para entender relaciones y posibles fugas de información.
- Columnas constantes o irrelevantes eliminadas: EmployeeCount (valor constante 1), StandardHours (valor constante 80), Over18 (valor único 'Y' en todas las filas) y EmployeeNumber (identificador único, no predictivo). Tras esta limpieza el dataframe quedó con 31 columnas.
- El desbalance en Attrition es marcado: 1,233 empleados (83.9%) con clase "No" y 237 (16.1%) con clase "Yes".

Distribución de variables categóricas relevantes

- BusinessTravel: Travel_Rarely (1,043), Travel_Frequently (277), Non-Travel (150).

- Department: Research & Development (961), Sales (446), Human Resources (63).
- OverTime: No (1,054), Yes (416).
- Gender: Male (882), Female (588).

3. Preprocesamiento reproducible

Se construyó un ColumnTransformer dentro de un Pipeline para garantizar reproducibilidad:

- Variables numéricas (22 features): escaladas con StandardScaler.
- Variables categóricas (7 features): codificadas con OneHotEncoder(handle_unknown='ignore'). Tras el encoding, el espacio de features queda en 50 columnas.
- Se eliminaron columnas con leakage potencial e irrelevantes (ver Sección 2).
- División de datos: 80% entrenamiento (1,176 muestras) y 20% prueba (294 muestras), con split estratificado en la variable Attrition para preservar la proporción de clases.

Se aplicó fit_transform sobre X_train y transform sobre X_test para evitar fuga de información entre conjuntos.

Features numéricas utilizadas: Age, DailyRate, DistanceFromHome, Education, EnvironmentSatisfaction, HourlyRate, JobInvolvement, JobLevel, JobSatisfaction, MonthlyRate, NumCompaniesWorked, PercentSalaryHike, PerformanceRating, RelationshipSatisfaction, StockOptionLevel, TotalWorkingYears, TrainingTimesLastYear, WorkLifeBalance, YearsAtCompany, YearsInCurrentRole, YearsSinceLastPromotion, YearsWithCurrManager.

Features categóricas utilizadas: BusinessTravel, Department, EducationField, Gender, JobRole, MaritalStatus, OverTime.

4. Modelado y diagnóstico

4.1 Regresión (MonthlyIncome)

Se entrenaron tres modelos de regresión y se evaluaron en el conjunto de prueba (294 muestras):

Modelo	RMSE	R ²
Regresión Lineal	1053.05	0.9541
Ridge ($\alpha=1.0$)	1052.80	0.9541
Lasso ($\alpha=0.1$)	1052.68	0.9541

Los tres modelos obtienen métricas prácticamente idénticas: un R² de 0.9541 indica que el modelo explica el 95.4% de la varianza en el ingreso mensual. El RMSE de ~1,053 representa el error promedio de predicción. La similitud entre modelos sugiere que la regularización (Ridge y Lasso) no aporta mejora sustancial, lo que indica que el modelo lineal es robusto y no sufre de multicolinealidad severa.

Se generaron curvas de aprendizaje para la Regresión Lineal (CV=5, scoring: neg_mean_squared_error). Las curvas no mostraron overfitting importante.

4.2 Clasificación (Attrition)

Modelo: Regresión Logística (solver='liblinear', random_state=42).

Distribución de clases en entrenamiento: No Attrition = 986 (83.8%), Attrition = 190 (16.2%).

Tabla 2: Matriz de confusión

	Pred. No Renuncia	Pred. Renuncia
Real: No Renuncia	237 (TN)	10 (FP)
Real: Renuncia	31 (FN)	16 (TP)

Tabla 3: Reporte de clasificación

Clase	Precision	Recall	F1-Score	Support
No Attrition	0.88	0.96	0.92	247
Attrition	0.62	0.34	0.44	47
Accuracy global	—	0.86	—	294

- Recall (clase Attrition): 0.3404 — el modelo identifica correctamente el 34% de los empleados que realmente renuncian.
- Accuracy global: 0.86, pero esta métrica es engañosa dado el desbalance de clases.
- AUC-ROC: 0.8128 — buena capacidad discriminativa general del modelo.
- AUC-PR: 0.5823 — métrica más relevante para clases desbalanceadas; indica desempeño moderado en la clase minoritaria.

5. Evaluación y métricas

5.1 Regresión

- RMSE: mide el error promedio en las predicciones de salario (~\$1,053). Métrica directamente interpretable en términos de negocio.
- R^2 : 0.9541 en los tres modelos. Los modelos explican el 95.4% de la varianza en el ingreso mensual.

5.2 Clasificación

- Dado el desbalance de clases (~16% positivos), se prioriza Recall y F1-Score sobre Accuracy.
- Recall de 0.3404 para la clase Attrition es bajo; el modelo detecta solo 16 de 47 renunciaciones reales en el conjunto de prueba.
- El AUC-ROC de 0.8128 indica que el modelo tiene buena capacidad de separación entre clases cuando se ajusta el umbral.
- El AUC-PR de 0.5823 refleja el desafío del desbalance: hay margen de mejora significativo en la detección de la clase minoritaria.
- Los 31 Falsos Negativos representan empleados que se van sin que el modelo lo detecte, siendo el error más costoso en este contexto.

6. Interpretación y decisiones

6.1 Variables que determinan el salario (MonthlyIncome)

Los coeficientes de los tres modelos de regresión son muy consistentes entre sí, lo que refuerza la robustez de los resultados.

Variables con mayor impacto positivo en el salario:

- JobRole_Manager (+3,490): ser Gerente es el factor individual más importante.
- JobRole_Research Director (+3,371): segundo rol mejor remunerado.
- JobLevel (+2,975): a mayor nivel jerárquico, mayor ingreso.
- TotalWorkingYears (+405): más años de experiencia total se asocian a mayor salario.

Variables con impacto negativo en el salario:

- JobRole_Laboratory Technician (-1,307): rol con mayor penalización salarial.
- JobRole_Sales Representative (-1,279): segundo rol con mayor brecha negativa.
- JobRole_Research Scientist (-1,220): tercer rol con coeficiente negativo importante.
- YearsWithCurrManager (-127): llevar mucho tiempo con el mismo jefe se asocia a estancamiento salarial.

6.2 Variables que predicen la renuncia (Attrition)

Coeficientes logísticos que aumentan la probabilidad de renuncia:

- JobRole_Laboratory Technician (+1.009): mayor riesgo de rotación entre todos los roles.
- JobRole_Sales Representative (+0.810): segundo rol con mayor riesgo.
- BusinessTravel_Travel_Frequently (+0.672): viajar frecuentemente aumenta el riesgo.
- OverTime_Yes (+0.594): hacer horas extra es un fuerte predictor de renuncia.
- YearsSinceLastPromotion (+0.531): la falta de ascensos recientes incrementa el riesgo.

Coeficientes logísticos que reducen la probabilidad de renuncia:

- OverTime_No (-1.248): no hacer horas extra es el factor protector más fuerte.
- JobRole_Research Director (-1.120): los directores de investigación tienen menor tendencia a irse.
- BusinessTravel_Non-Travel (-1.105): no viajar reduce significativamente el riesgo.
- EnvironmentSatisfaction (-0.471): mayor satisfacción con el ambiente laboral retiene al empleado.

6.3 Recomendaciones

Basadas en la interpretación de los modelos:

- Transparentar escalas salariales por JobLevel y crear trayectorias de carrera claras para roles técnicos (Técnicos de Laboratorio, Representantes de Ventas) que muestran baja remuneración y alta rotación.
- Implementar políticas de control de overtime: es el predictor más fuerte tanto de insatisfacción como de renuncia.
- Revisar frecuencia de viajes para roles de ventas y establecer políticas de compensación por desplazamiento.
- Priorizar revisiones salariales y planes de ascenso para empleados con alto YearsSinceLastPromotion.
- Ajustar el umbral de clasificación por debajo de 0.5 para maximizar Recall manteniendo una Precision aceptable, dado que el costo de los FN supera al de los FP.

7. Limitaciones y trabajo futuro

- Los modelos son lineales; podrían explorarse árboles de decisión, ensambles (Random Forest, Gradient Boosting) o redes neuronales para mejorar el Recall en Attrition.
- El Recall de 0.3404 es insuficiente para producción; se recomienda aplicar técnicas de balanceo como SMOTE o `class_weight='balanced'` en la regresión logística.
- No se incorporaron interacciones entre variables ni features derivadas que podrían aumentar la capacidad predictiva.
- Se usó un único conjunto de prueba fijo (20%); un pipeline de validación cruzada (k-fold estratificado) garantizaría estimaciones más robustas.
- Interpretación de coeficientes asume relación lineal; algunas variables podrían requerir transformaciones (log, polinomios).
- El dataset proviene de una sola empresa; los modelos pueden no ser generalizables a otros contextos organizacionales.
- No se analizó la evolución temporal de los datos; datos más recientes podrían reflejar patrones distintos.

8. Repositorio y reproducibilidad

- El notebook .ipynb adjunto corre de extremo a extremo sin errores (requiere ajuste de rutas de Google Drive para entorno local).
- La semilla aleatoria utilizada es `random_state=42` en todos los modelos y splits.
- El pipeline de preprocesamiento (ColumnTransformer) garantiza que no haya fuga de información entre train y test.

Link de GitHub: <https://github.com/Alanffc/Talent-Retention-Analytics.git>

- El repositorio público contiene el notebook, el dataset CSV, y esta documentación.
- Se incluye un README con instrucciones para ejecutar el análisis desde cero.